


Varianssianalyysi

Tutkitaan, onko sukupuolella ja asumisahtaudella yhteyttä asunnon pinta-alaan. Kyseessä on kaksi kategorista selittävää muuttujaa, sekä yksi numeerinen selitettävä muuttuja, joten käytetään kaksisuuntaista varianssianalyysiä.

Tarkastellaan ensin aineistoa kuvailevia tunnuslukuja ja niiden boxplot-kuvaajia. Kun tarkastellaan keskiarvoja ja mediaaneja, niin huomataan että havaintoja vastaavat kuvaajat ovat kaikki oikealle vinoja. Tämän huomaa siitä, että keskiarvo on suurempi kuin mediaani. Vinoimpina ahdas-nainen sekä tilava-nainen. Keskiarvot ovat suurinpiirtein samat kaikissa luokissa. Huomioitavaa myös ylöspäin poikkeavat havainnot naisten kuvaajassa.



Vas. miehet, oik. naiset

ANOVA-tutkintaan on olennaista varmistaa kategoristen muuttujien normalisuus sekä populaatioiden hajontojen yhtäsuuruus. ANOVAn nollahypoteesina on, että tutkittujen muuttujien odotusarvot ovat samat sukupuolien välillä. Nollahypoteesille kriittiset p-arvot ovat $< \alpha$. Tutkitaan aineistoa merkitsevyystasolla $\alpha=0.05$. On siis suotavaa että normalisuusoletus toteutuu.

Normalisuusoletus testaus Shapiro-Wilk - testillä.

Miehet:

Ahdas	p-arvo = 0.03229
Normaali	p-arvo = 0.003136
Tilava	p-arvo = 0.01487

Naiset:

Ahdas	p-arvo = 7.198e-06
-------	--------------------

Normaali	p-arvo = 3.818e-10
Tilava	p-arvo = 3.509e-05

Valitulla merkitsevyystasolla nollahypoteesi hylätään kaikille havainnoille (p-arvot <0.05). Havaintoja on tosin selvästi yli 100 eli otoskeskiarvojen otantajakaumia voidaan pitää normaalijakaumina keskeisen raja-arvolauseen mukaan.

Testataan nyt populaation hajontojen yhtäsuuruutta Levene-testillä.

Saadaan $p=7.148e-07$ (<0.05), eli ero populaatiohajontojen välillä on tilastollisesti merkitsevää. Levenen testi ei siis tue testattavaa hypoteesia populaatiohajontojen yhtäsuuruudesta, mikä ei ole toivottavaa. Edetään silti kaksisuuntaiseen varianssianalyysiin, vaikka yleisesti ottaen näin ei kuuluisi tehdä.

Pinta-ala ~ sukupuoli saatu F-arvo= 4.88, p-arvo= 0.0274

Saatu p-arvo on tilastollisesti merkitsevä merkitsevyystasolla 0.05. Täten p-arvo hylkää nollahypoteesin. Melko korkea F-testin arvo vahvistaa tämän päätelmän. Sukupuolien väliset erot asumispinta-aloissa ovat siis tilastollisesti merkitsevät.

Pinta-ala ~ asumisahtaus saatu F-arvo= 139.8, p-arvo< 2e-16

Saatu p-arvo on erittäin pienenä arvona tilastollisesti merkitsevä tutkitulla merkitsevyystasolla. Korkea F-testin arvo vahvistaa myös nollahypoteesin hylkäystä. Aukkaiden kokemilla asumisahtauksilla on siis tilastollisesti merkittäviä eroja asuntojen pinta-aloihin. Eli suuressa asunnossa asuva voi kokea asuntonsa ahtaaksi ja myös päinvastoin.

Asumisahtauden ja sukupuolen yhdysvaikutus saatu F-arvo= 0.825, p-arvo= 0.43863

Saatu suuri p-arvo tarkoittaa ettei asumisahtauden ja sukupuolen yhdysvaikutus ole tilastollisesti merkitsevä.

Tulkinta:

Päävaikutukset ovat tilastollisesti merkitseviä ja yhdysvaikutus ei, joten voidaan siirtyä monivertailuihin selittävien muuttujien osalta.

Monivertailut Tukeyn testillä

Ahtaus	Erotus	95% LV:n alaraja	95% LV:n yläraja	p-arvo
normaali-ahdas	≈23.27	≈13.94	≈32.61	>0.001
tilava-ahdas	≈72.99	≈61.65	≈84.32	>0.001
tilava-normaali	≈49.71	≈41.78	≈57.65	>0.001

Tulkinta:


Kaikki erot keskiarvojen välillä ovat tilastollisesti merkitseviä ($p < 0.001$). Normaali-kokoisten asuntojen asukkaat elävät keskimäärin 23.27 neliömetriä suuremmissa asunnoissa kuin ahtaiden asuntojen asukkaat. Tilavien asuntojen asukkaat asuvat 72.99 neliömetriä suuremmissa asunnoissa kuin ahtaiden asuntojen asukkaat. Tilavien asuntojen asukkaat asuvat 49.71 neliömetriä suuremmissa asunnoissa kuin normaalien asuntojen asukkaat.

Sukupuoli	Erotus	95% LV:n alaraja	95% LV:n yläraja	p-arvo
nainen-mies	≈ -6.93	≈ -11.67	≈ -2.18	≈ 0.004

Tulkinta sukupuolen suhteen:

Ero keskiarvojen välillä on tilastollisesti merkitsevä (p-arvo ≈ 0.004). Naiset asuvat keskimäärin noin 6.93 neliömetriä pienemmissä asunnoissa kuin miehet.

Keskiarvojen profiilikuvio:



Mallin populaatiohajontojen yhtäsuuruus ei toteudu, mikä on huonoksi mallille.

Regressiomalli

Tutkitaan, onko kotitalouden kuluttajayksiköiden lukumäärällä, asumismenoilla yhteensä ja alueella asumisaikalla yhteyttä asunnon pinta-alaan.

1. Tutkitaan ensin onko selittäjien välillä kollineaarisuutta.

Soluissa nähdään Pearsonin korrelaatiokertoimet. Nämä mittaavat lineaarista riippuvuutta muuttujien kesken.


	kotitalouden kuluttajien määrä	asumismenot yht	alueella asumisaika
Kotitalouden kuluttajien määrä	1	0.1405467	-0.01705633
asumismenot yht	0.1405467	1	-0.2447815
alueella asumisaika	-0.01705633	-0.2447815	1

Tulkinta:


Pearsonin korrelaatiokertoimista ei havaita vahvoja riippuvuuksia. Asumismenojen sekä asumisajan välillä on kohtalainen negatiivinen lineaarinen riippuvuus.

2. Sirontakuviot ja korrelaatiokertoimet selittävien ja selitettävän muuttujan, eli asunnon pinta-alaan välillä.


Sirontakuvio, jossa selittäjänä kotitalouden kuluttajayksiköiden lukumäärä:



Sirontakuvio, jossa selittäjänä asumismenot yhteensä:



Sirontakuvio, jossa selittäjänä alueella asumisaika:



Tulkinta:

Voidaan havaita että PNS-suora sopii ainoastaan ensimmäiseen sirontakuviin, jossa näkyy selkeää lineaarista riippuvuutta. Tässä selittävänä muuttujana on kotitalouden kuluttajayksiköiden lukumäärä ja selitettävänä muuttujana on asunnon pinta-ala.

Korrelaatiokertoimet

	Pearsonin korrelaatiokerroin (r)	Spearmanin korrelaatiokerroin (r_s)
kotitalouden kuluttajayksiköiden lukumäärä	0.5003798	0.5753453
asumismenot yhteensä	0.06620424	0.04841135
alueella asumisaika	0.1190545	0.1967941

Tulkinta:

Muuttujista vain kotitalouden ja kuluttajayksiköiden lukumäärä on järkevä ottaa mukaan selittäjäksi regressioanalyysiin. Vaikka Pearsonin korrelaatiokerroin onkin Spearmanin korrelaatiota pienempi ($r < r_s$), niin $r \geq 0.5$, mikä sallii valinnan. Lineaarinen riippuvuus on siis tässä tarpeeksi voimakasta. Muilla selittäjillä ei havaita tarpeeksi lin. riippuvuutta, joten paras on pudottaa nämä pois. Myös huomattavaa että alueella asumisajan kohdalla myös $r < r_s$.

3. Regressioanalyysi, jossa selittäjänä kotitalouden kuluttajayksiköiden lukumäärä ja selitettävänä muuttujana asunnon pinta-ala.

Mallin tilastollinen merkitsevyys:

t-testin p-arvo < 0.001 eli malli on tilastollisesti merkitsevä.

Selitysaste:

Mallin selitysaste $R^2 \approx 0.25$ eli noin 25 %. Toisin sanoen estimoitu malli on selittää noin 25 % selitettävän muuttujan arvojen vaihtelusta. Selitysaste on siis melko heikko.

Regressioyhtälö:

$$\hat{y} = b_0 + b_1 x, \text{ jossa}$$

$\hat{y}$ = "asunnon pinta-alan ennustearvo"

x = "kotitalouden kuluttajayksiköiden lukumäärä"

$$b_0 = 26.952$$

$$b_1 = 25.541$$


Mallista nähdään, että mitä enemmän kuluttajayksiköitä, sitä enemmän keskimäärin asunnossa on pinta-alaa. Regressiomallin mukaan yhden kotitalouden kuluttajayksikön ero merkitsee keskimäärin noin 25.5:n neliömetrin eroa asumistilassa.

Jäännöstarkastelu

Tutkitaan histogrammista, ovatko jäännökset normaalisti jakautuneita.



Histogrammi ei ole symmetrinen. Se on oikealle vino, joten nähdään etteivät jäännökset ole normaalisti jakautuneita.



Nähdään myös että jäännösten hajonta ei ole samanlaista ennustearvojen arvoalueella. hajonta nousee noin 80:een asti ja alkaa laskea suurempien ennustearvojen myötä. Malli ei siis ole kovin tehokas ennustamaan asunnon pinta-alaa.

Toistomittausmalli

Tutkijalla on hypoteesi, että potilaan mielestä saatu ohjaus leikkauksen jälkeen toiminnallista seikoista (Functional_M2) on ollut vähäisempää kuin odotettu ennen leikkausta (Functional_M1). Eli keskiarvo toisessa mittauksessa on matalampi. Lisäksi kiinnostaa se, onko tuo ero mittauksen välillä erilainen sukupuolittain.

Otetaan aineistosta erikseen kiinnostavat muuttujat sekä poistetaan puuttuvia havaintoja sisältävät havaintoyksiköt. Jäljelle jää 488 havaintoyksikköä.

Kuvailevat tunnusluvut

	keskiarvo	mediaani	keskihajonta
odotettu ohjaus ennen leikkausta	3.639	4.000	0.6174231
saatu ohjaus leikkauksen jälkeen	3.328	3.500	0.709449

Tulkinta:

Keskiarvo on suurempi odotetussa ohjauksessa ennen leikkausta kuin saadussa ohjauksessa leikkauksen jälkeen. Sama pätee mediaanille. Keskiarvo on pienempi kuin mediaani molemmissa, joten laatikkojanakuviot ovat vasemmalle vinoja. Keskihajonta on suurempi saadussa ohjauksessa leikkauksen jälkeen kuin odotetussa ohjauksessa ennen leikkausta.

Naiset:

	keskiarvo	mediaani	keskihajonta
odotettu ohjaus ennen leikkausta	3.614760	4	0.6700352
saatu ohjaus leikkauksen jälkeen	3.272384	3.500	0.7572496

Miehet:

	keskiarvo	mediaani	keskihajonta
odotettu ohjaus ennen leikkausta	3.668861	4	0.5140850
saatu ohjaus leikkauksen jälkeen	3.422406	3.625	0.6086888


Tulkinta:

Laatikkojanakuviot ovat vasemmalle vinoja sillä keskiarvo on pienempi kuin mediaani odotetussa ohjauksessa ennen leikkausta ja saadussa ohjauksessa leikkauksen jälkeen niin miesten kuin naisten luokissa. Keskiarvot ja mediaanit ovat pienempiä saadussa ohjauksessa leikkauksen jälkeen kuin odotetussa ohjauksessa ennen leikkausta molemmilla sukupuolilla. Keskihajonnat taas vastaavasti suurempia sekä miehillä että naisilla saadussa ohjauksessa leikkauksen jälkeen verrattuna odotettuun ohjaukseen ennen leikkausta.

Keskiarvot odotetussa ohjauksessa ovat lähes yhtä suuret odotetussa ohjauksessa ennen leikkausta naisilla ja miehillä, mutta naisten keskiarvo saadussa ohjauksessa leikkauksen jälkeen naisilla on pienempi kuin miehillä. Mediaanit ovat sama naisilla ja miehillä odotetussa ohjauksessa ennen leikkausta, mutta pienempi naisilla saadussa ohjauksessa leikkauksen jälkeen. Keskihajonta on suurempi naisilla kuin miehillä niin saadussa ohjauksessa leikkauksen jälkeen kuin edeltävässä odotetussa ohjauksessa.

Laatikkojanakuviot


sukupuolineutraali:




1 = "odotettu ohjaus ennen leikkausta" 2 = "saatu ohjaus leikkauksen jälkeen"

sukupuolittain:

odotettu ohjaus ennen leikkausta



saatu ohjaus leikkauksen jälkeen



Normaalisuusoletuksen testaus Shapiro-Wilk -testeillä

Sukupuolineutraalista aineistosta:

odotettu ohjaus ennen leikkausta

$p < 0.001$

saatu ohjaus leikkauksen jälkeen

$p < 0.001$

Sukupuolittain:

odotettu ohjaus ennen leikkausta

Miehet	p<0.001
Naiset	p<0.001

saatu ohjaus leikkauksen jälkeen

Miehet	p<0.001
Naiset	p<0.001

Tulkinta:

Shapiro-Wilk -testien p-arvot < 0.001 eli normaalisuusoletus ei toteudu, mutta koska havaintoja on suuri määrä, voidaan otoskeskiarvojen otantajakaumia voidaan pitää normaalijakaumina keskeisen raja-arvolauseen mukaan. Edetään siis toistettujen mittausten varianssianalyysiin.

Toistettujen mittausten varianssianalyysi

Sukupuolten mukaan saatu F-testin p-arvo 0.0176 (< 0.05), eli ero sukupuolten välillä on tilastollisesti merkitsevä.

Ohjauksen mukaan saatu F-testin p-arvo <0.001, eli mittausten välinen ero on tilastollisesti merkitsevä.

Yhdysvaikutuksen saatu F-testin p-arvo 0.2624 (>0.05), eli yhdysvaikutus ei ole tilastollisesti merkitsevä.

Tulkinta:

Toistotekijän (ohjauksen) ja luokittelevan tekijän (sukupuolen) vaikutukset ovat tilastollisesti merkitseviä, mutta yhdysvaikutus ei. Voimme siis siirtyä monivertailuihin luokittelevan tekijän, eli sukupuolen osalta.

Monivertailut parittaisin t-testein

sukupuolineutraali

	keskiarvojen välinen erotus	95% LV:n alaraja	95% LV:n yläraja	p-arvo
odotettu vs saatu ohjaus	≈ 0.307	≈ 0.238	≈ 0.377	< 0.001

miehet:

	keskiarvojen välinen erotus	95% LV:n alaraja	95% LV:n yläraja	p-arvo
odotettu vs saatu ohjaus	≈ 0.246	≈ 0.150	≈ 0.343	< 0.001


naiset:

	keskiarvojen välinen erotus	95% LV:n alaraja	95% LV:n yläraja	p-arvo
odotettu vs saatu ohjaus	≈ 0.342	≈ 0.247	≈ 0.437	< 0.001

Tulkinta:

Tutkitut hypoteesit saavat tukea toistettujen mittausten varianssianalyysistä. Jos ei kiinnitetä huomiota sukupuoleen, odotetun ohjauksen ja saadun ohjauksen keskiarvojen välinen ero on noin 0.30, eli odotetun ohjauksen keskiarvo on noin 0.30 verran suurempi kuin saadun ohjauksen keskiarvo, ja tämä ero on tilastollisesti merkitsevä (p-arvo < 0.001). Naisten odotetun ja saadun ohjauksen keskiarvojen välinen ero on noin 0.34, eli odotetun ohjauksen keskiarvo on noin 0.34 verran suurempi kuin saadun ohjauksen keskiarvo, miesten vastaava on noin 0.25, eli odotetun ohjauksen keskiarvo on noin 0.25 verran suurempi kuin saadun ohjauksen keskiarvo, ja molemmat keskiarvojen väliset erot ovat tilastollisesti merkitseviä (p-arvot < 0.001), joten ero mittausten välillä on erilainen sukupuolittain. Naisten keskiarvojen välinen ero on noin 0.1 suurempi kuin miehillä.

Keskiarvojen profiilikuvio:



Kategoristen vastemuuttujien mallitus

Muuttujien riippuvuus rakenne

1. Tarkastellaan muuttujia sukupuoli, työttömyys viimeisen 12 kuukauden aikana ja oman sukupuolen 2011 eduskuntavaaleissa äänestäminen. Tehdään yksiulotteiset frekvenssijakaumat ja kolmen muuttujan ristiintaulu.

Yksiulotteiset frekvenssijakaumat:

sukupuoli

mies	nainen
394	394

työttömyys viime 12kk aikana

en	kyllä
689	99

oman sukupuolen äänestäminen eduskuntavaaleissa 2011

ei	kyllä
263	417

kolmen muuttujan ristiintaulu

		oman sukupuolen äänestäminen eduskuntavaaleissa 2011	
sukupuoli	työttömyys viimeisen 12kk aikana	en	kyllä
mies	en	92	219
	kyllä	16	25
nainen	en	134	156
	kyllä	21	17

Ristiintaulussa ei ole nollasoluja. Pienin frekvenssi on 16.

2. Sukupuoli ja työttömyys viimeisen 12 kuukauden aikana ovat riippumattomia toisistaan. Sukupuolen ja oman sukupuolen 2011 eduskuntavaaleissa äänestämisen välillä ilmenee riippuvuussuhde. Työttömyyden viimeisen 12 kuukauden aikana ja oman sukupuolen 2011 eduskuntavaaleissa äänestämisen välillä ilmenee riippuvuussuhde. Kyseessä on siis ehdollinen riippumattomuusmalli.

Mallin generoiva luokka:

{AB, AC}, jossa

A = "oman sukupuolen 2011 eduskuntavaaleissa äänestäminen"

B = "sukupuoli"

C = "työttömyys viimeisen 12 kuukauden aikana"

Mallin yhteensopivuustestin p-arvo:

χ^2 -testin p-arvo ≈ 0.95 , joka ylittää helposti mallin kriteerirajan (väh 0.1).

Standardoitujen jäännösten vaihteluväli:

Mallin standardoidut jäännökset ovat välillä [-0.7101595, 0.9345564]. Jäännökset ovat pieniä, joten malli sopii hyvin kuvaamaan kolmen muuttujan keskinäisiä yhteyksiä.

3. Tehdään mallin mukainen yhteyksien jatkotarkastelu ristiintaulujen avulla (2 riippuvuussuhdetta eli 2 taulukkoa) ja tarkastellaan mallia rivien prosenttien mukaan

Oman sukupuolen äänestäminen eduskuntavaaleissa 2011	sukupuoli	
	mies	nainen
en	≈ 0.41	≈ 0.59
kyllä	≈ 0.59	≈ 0.41

tulkinta:

Nähdään että naiset äänestivät harvemmin oman sukupuolensa edustajaa eduskuntavaaleissa kuin miehet

Oman sukupuolen äänestäminen eduskuntavaaleissa 2011	Työttömyys viimeisen 12kk aikana	
	en	kyllä
en	≈ 0.86	≈ 0.14
kyllä	≈ 0.90	≈ 0.10

tulkinta:

huomataan että työttömyydellä saattaa olla pieni vaikutus oman sukupuolen äänestämiseen. Myös suurin osa väestöstä ei ole ollut työttömänä viime 12kk aikana

Kaksiluokkainen selittävä muuttuja

1.

Sukupuoli: Z-testin p-arvo = 0.96, täten sukupuoli ei ole tilastollisesti merkitsevä tekijä

Ikä: Z-tesin p-arvo < 0.001, eli ikä on tilastollisesti merkitsevä tekijä työttömyyttä mallintaessa.

selittävä muuttuja	p-arvo	Odds Ratio	95% LV alaraja OR:lle	95% LV yläraja OR:lle
ikä	<0.001	≈ 0.966	≈ 0.954	≈ 0.978

tulkinta:

Jokainen ikävuosi vähentää todennäköisyyttä olla työttömänä viimeisen 12 kuukauden aikana noin 3.4 % verran.

Mallin Nagelkerke selitysaste:

$R^2 \approx 0.076$, eli huono. Tosin ei verrattavissa varsinaiseen R^2 - testiin.

Monimuuttujamenetelmät

Poimitaan 1600 kokoinen satunnaisotos pankin asiakasaineistosta (n=1598, kun poistetaan puuttuvat havainnot).

Muuttujien ryhmittely

Muodostetaan pääkomponenttianalyysillä luokitelluista muuttujista pääkomponentteja ominaisarvokriteerin mukaan.

1. Pääkomponenttianalyysin edellytysten tarkastelu.

Aineistosta löytyy muuttujia, jotka eivät tilastollisesti merkitsevästi korreloi muihin muuttujiin, joten kaikki korrelaatiot eivät ole tilastollisesti merkitseviä. Huomattava osuus korrelaatioista on silti tilastollisesti merkitseviä.

Bartlettin sfäärisyystesti ja Kaiser-Meyer-Olkin -testi:

kriteerilaji	otoksesta laskettu	toteutuuko edellytys
KMO-suure	0.7	kyllä
Bartlettin suureen p-arvo	<0.001	kyllä

Korrelaatiomatriisin sopivuus pääkomponenttianalyysiin on hyvä, sillä Bartlettin testin mukaan korrelaatiomatriisin arvot poikkeavat tilastollisesti merkittävästi nolasta ja KMO-testin mukaan korrelaatiomatriisi on myös sopiva ($KMO = 0.7 > 0.6$).

Pääkomponenttien lukumäärä ominaisarvokriteerin perusteella ja pääkomponenttien yhteinen selitysprosentti muuttujien vaihtelusta:

Muuttujat	pääkomponenttien lkm	kumulatiivinen selitysprosentti
autom_lainan_perinta_luok- kulutusluot1 luok	13	0.62530

Valitaan 5 pääkomponenttia selkeyden vuoksi ja siksi, että jätettyjen pääkomponenttien selitysprosentit ovat melko pieniä. Valittujen 5 pääkomponentin kumulatiivinen selitysprosentti on 0.38318

Pääkomponenttianalyysi

Tutkitaan muuttujien Promax-rotatation mukaisia latauksia pääkomponentteihin

	PC1	PC2	PC3	PC4	PC5
autom_lainan_perinta_luok				0.404	
lainojen_lukumaara_luok				0.393	
asuntoluotot1_luok				0.451	
automaattinostaja_luok	0.410				
vakuutus_a_luok			-0.238		
asuntolaina_a_kpl_luok				0.225	
asuntolaina_b_kpl_luok					
vakuutus_b_luok			-0.243		
vakuutus_c_luok		-0.136	-0.153		
korkeakork_kpl_luok		-0.222			0.141
rahasto_a1_luok			-0.238		
pankkikorttilkm_luok	0.324				-0.155
luottokortteja_yhteensa_luok	0.115		-0.116		
maaraaikaistileja_luok		-0.317			
maksuautomaattitapahtumia_luok	0.312	0.120			
kayttotili_tal_luok		-0.356			
kayttotili_vel_luok					
asuntolaina_c_kpl_luok				0.326	0.117
osakkeet_euroa_1_luok					0.553
eri_osakesarjoja_luok			-0.156		0.557
rahasto_b1_luok			-0.436		0.116
ottoja_luok	0.397				
pkorttimaksuja_luok	0.370				
panoja_luok	0.329	-0.178			
asuntolaina_d_kpl_luok			-0.102	0.240	
palveluja_kpl_luok	0.222			0.167	
rahastolajeja_luok			-0.580		
lainarastit_luok				0.215	
saastotililla_luok		-0.412			
asuntolaina_e_kpl_luok				0.163	
suoraveloituuksia_luok	0.116	-0.330			0.151
netissa_maksut_luok	0.221	0.102			0.156
maksupalvelussa_maksut_luok		-0.429			
tiskilla_maksut_luok		-0.357			
tilinylityspaivat_luok	0.204	0.109			-0.110
toimeksianto_a_kpl_luok					0.275
toimeksianto_b_kpl_luok					0.171
kv_maksukortit_luok				0.113	0.292
rahasto_c1_luok			-0.452		
korttiluotot1_luok	0.166				
kulutusluotot1_luok				0.287	-0.114
SS loadings	1.002	1.006	1.030	1.003	1.026
Proportion Var	0.024	0.025	0.025	0.024	0.025
Cumulative Var	0.024	0.049	0.074	0.099	0.124

Huomioidaan erityisesti suuret (>0.3) lataukset

-Muuttujat, jotka ovat latautuneet pääkomponenttiin 1:

automaattinostoja_luok, pankkikorttilkm_luok, maksuautomaattitapahtumia_luok, ottoja_luok, pkorttimaksuja_luok, panoja_luok.

Nimetään pääkomponentti 1 siihen latautuneiden muuttujien mukaan nimellä "korttiaktiivisuus".

-Muuttujat, jotka ovat latautuneet pääkomponenttiin 2:
maaraaikaistileja_luok, kayttotili_tal_luok, saastotililla_luok, suoraveloituksia_luok, maksupalvelussa_maksut_luok, tiskilla_maksut_luok

Nimetään pääkomponentti 2 siihen latautuneiden muuttujien mukaan nimellä "tiliaktiivisuus".

-Muuttujat, jotka ovat latautuneet pääkomponenttiin 3:
rahasto_b1_luok, rahastolajeja_luok ja rahasto_c1_luok (latautuneet negatiivisesti).

Nimetään pääkomponentti 3 siihen latautuneiden muuttujien mukaan nimellä "rahastot".

-Muuttujat, jotka ovat latautuneet pääkomponenttiin 4:
autom_lainan_perinta_luok, lainojen_lukumaara_luok, asuntoluotot1_luok, asuntolaina_c_kpl_luok, kulutusluotot1_luok.

Nimetään pääkomponentti 4 siihen latautuneiden muuttujien mukaan nimellä "lainat/luotot".

Muuttujat, jotka ovat latautuneet pääkomponenttiin 5:
osakkeet_euroa_1_luok ja eri_osakesarjoja_luok.

Nimetään pääkomponentti 5 siihen latautuneiden muuttujien mukaan nimellä "osakkeet".

Pääkomponenttien keskinäiset korrelaatiot ovat kaikki <0.001

Tulkinta:

Saatiin melko selkeät pääkomponentit järjestettyä latauksien mukaan.

Havaintojen ryhmittely


Käytetään pääkomponentteihin latautuneiden muuttujien uusia nimettyjä muuttujia (korttiaktiivisuus, tiliaktiivisuus, rahastot, lainat/luotot ja osakkeet) klusterianalyysissä. Muodostetaan asiakasryhmiä K-means menetelmällä lähtien kahdesta klusterista viiteen klusteriin saakka. Kuvailaan muodostettuja ryhmiä.

Aloitetaan kahdesta klusterista:

		keskiarvot				
klusteri	havaintoja	korttiaktiivisuus	rahastot	tiliaktiivisuus	lainat/luotot	osakkeet
1	931	≈ -1.739	≈ -0.027	≈ -0.197	≈ 0.196	≈ 0.006
2	667	≈ 2.423	≈ 0.037	≈ 0.276	≈ -0.274	≈ 0.008

tulkinta:

Klusterssa 1 on huomattavasti vähemmän aktiivisia kortin käyttäjiä. Klusteriin 2 kuuluu aktiivisempi käyttäjiä jotka ottavat myös vähemmän lainoja ja sijoittavat osakkeisiin ja rahastoihin hieman enemmän.



Klusteri 1 on sisäisesti hyvin homogeeninen toisin kuin klusteri 2. Klustereiden tulisi olla ulkoisesti hyvin heterogeenisiä, joita ne eivät selvästikään ole. Ne myös leikkaavat hieman toisiaan mikä yleisesti ei ole hyväksi mallille.


Lisätään nyt ryhmien määrä kolmeen.

		keskiarvot				
klusteri	havaintoja	korttiaktiivisuus	rahastot	tiliaktiivisuus	lainat/luotot	osakkeet
1	57	≈ 2.042	≈ -5.811	≈ -3.343	≈ -2.175	≈ -2.410
2	901	≈ -1.778	≈ 0.020	≈ -0.160	≈ 0.251	≈ 0.056
3	640	≈ 2.321	≈ 0.489	≈ 0.530	≈ -0.159	≈ 0.136

Klusterissa 1 on aktiivisia kortin käyttäjiä, jotka eivät muutoin ole aktiivisia sijoittamisessa tai lainojen ottamisessa yms. Nämä pieni määrä havaintoja käyttävät tiliään pitkälti kortin käyttöä varten.

Klusterissa 2 on paljon havaintoja. Klusterin havaintoyksiköt eivät ole aktiivisia kortin käyttäjiä eivätkä muulla lailla kovin poikkea keskiarvoista.

Klusteri 3 on myös melko suuri. tähän klusteriin kuuluu aktiivisimmat kortin käyttäjät, jotka osallistuvat myös sijoittamiseen. Heidän pankkitilitoimintansa on myös melko aktiivisia.



Klusterit eivät ole ulkoisesti heterogeenisiä. Klusteri 2 on sisäisesti homogeeninen. Klusteri 1 on sisäisesti hyvin heterogeeninen, kun klusteri 3 on melko homogeeninen.

tutkitaan nyt neljää klusteria.


		keskiarvot				
klusteri	havainnot	korttiaktiivisuus	rahastot	tiliaktiivisuus	lainat/luotot	osakkeet
1	566	≈ 0.970	≈ 0.200	≈ 1.056	≈ -0.891	≈ 0.091
2	216	≈ 4.173	≈ 0.935	≈ -0.687	≈ 1.578	≈ 0.109
3	760	≈ -2.055	≈ 0.017	≈ -0.341	≈ 0.379	≈ 0.082
4	56	≈ 1.982	≈ -5.868	≈ -3.397	≈ -2.224	≈ -2.447

Klusterissa 1 on melko aktiivisia pankkikortin käyttäjiä, jotka sijoittavat hieman rahastoihin, ovat aktiivisia pankkitili-toiminnassa, eivätkä ota paljoa lainaa/luottoa.

Klusteriin 2 kuuluvat havintoyksiköt ovat erittäin aktiivisia pankkikortin käyttäjiä jotka ottavat myös paljon lainaa/luottoa ja sijoittavat melko paljon rahastoihin. Heidän pankkitilitoimintansa ei ole kovin aktiivista.

Klusteri 3 koostuu havaintoyksiköistä jotka eivät ole aktiivisia kortin käyttäjiä. heidän muu toimintansa ei kovinkaan poikkea keskiarvosta.

Klusteri 4 lienee lähes sama klusteri kuin aiemmin kolmesta klusterista saatu klusteri 1. Tässä klusterissa siis on aktiivisia kortin käyttäjiä, jotka eivät muutoin ole aktiivisia sijoittamisessa tai lainojen ottamisessa yms. Nämä pieni määrä havaintoja käyttävät tiliään pitkälti kortin käyttöä varten.



Vieläkään klusterit eivät ole heterogeenisiä. klusterit 2 ja erityisesti 3 ovat sisäisesti homogeenisiä. Klusteri 4 on yhä erittäin heterogeeninen.

Tutkitaan viittä klusteria


		keskiarvot				
klusteri	havainnot	korttiaktiivisuus	rahastot	tiliaktiivisuus	lainat/luotot	osakkeet
1	208	≈ 4.128	≈ 1.006	≈ -0.732	≈ 1.570	≈ 0.110
2	638	≈ -2.177	≈ 0.435	≈ -0.681	≈ 0.163	≈ 0.097
3	209	≈ -0.450	≈ -2.444	≈ 1.868	≈ 1.222	≈ 0.178
4	54	≈ 2.047	≈ -5.820	≈ -3.551	≈ -2.321	≈ -2.556
5	489	≈ 1.013	≈ 0.692	≈ 0.794	≈ -1.146	≈ 0.032

Klusteri 1 koostuu havaintoyksiköistä jotka ovat erittäin aktiivisia kortin käyttäjiä, ottavat paljon lainaa ja sijoittavat erityisesti rahastoihin. He eivät tosin ole aktiivisia pankkitilitoiminnoissa.

Klusteriin 2 kuuluu yksiköitä jotka eivät käytä usein pankkikorttia eivätkä ole kovin aktiivisia pankkitilitoiminnoissa. He sijoittavat keskiarvoa enemmän rahastoihin.

Klusterissa 3 olevat yksiköt eivät sijoita rahastoihin, mutta käyttävät aktiivisesti pankkitiliään ja ottavat myös melko paljon lainaa/luottoa.

Klusteri 4 koostuu lähes samoista yksiköistä kuin neljän klusterin mallin viimeinen klusteri. Tässä klusterissa siis on aktiivisia kortin käyttäjiä, jotka eivät muutoin ole aktiivisia sijoittamisessa tai lainojen ottamisessa yms. Nämä pieni määrä havaintoja käyttävät tiliään pitkälti kortin käyttöä varten.



Klusterit eivät ole vieläkaan ulkoisesti heterogeenisiä eivätkä myöskään tarpeeksi sisäisesti homogeenisiä. Merkittävimmin sis. homogeenisiä ovat klusteri 5 ja erityisesti klusteri 2.

Koodit

Varianssianalyysi:

```
library(foreign)
ht1.dat<-read.spss("elinolo2020.sav", to.data.frame=TRUE)
attach(ht1.dat)
# Suluissa olevan 1:n tilalle oma opiskelijanumero
set.seed(520829)
# 800 kokoinen otos
oma.otos1<-ht1.dat[sample(nrow(ht1.dat), 800), ]
attach(oma.otos1)
library(tidyverse)
library(dplyr)
library(ggplot2)

#keskiarvot soluittain
with(oma.otos1,tapply(pala,list(supu,ahtas),mean))

#mediaanit soluittain
with(oma.otos1,tapply(pala,list(supu,ahtas),median))

#keskihajonnat soluittain
with(oma.otos1,tapply(pala,list(supu,ahtas),sd))

#tutkitaan miesten havaintojen normaalisuutta Shapiro-Wilk- testin avulla
raj.ainM <- select(filter(oma.otos1, supu=="mies"),c(supu,ahtas,pala))
with(raj.ainM,tapply(pala,list(ahtas),shapiro.test))
attach(raj.ainM)

#laatikko-jana -kuvio, miehet
boxplot(pala~ahtas)
detach(raj.ainM)

#tutkitaan naisten havaintojen normaalisuutta Shapiro-Wilk -testin avulla
raj.ainN <- select(filter(oma.otos1, supu=="nainen"),c(supu,ahtas,pala))
with(raj.ainN,tapply(pala,list(ahtas),shapiro.test))
attach(raj.ainN)

#laatikko-jana -kuvio, naiset
boxplot(pala~ahtas)
detach(raj.ainN)

#populaatioiden hajontojen yhtäsuuruustestaus Levene-testillä
attach(oma.otos1)
library(car)
leveneTest(pala~ahtas*supu)

#nimetään malli ja suoritetaan kaksisuuntainen varianssianalyysi
```

```
fit1<-lm(pala ~ahtas*supu, data=oma.otos1)
malli_lm1<-aov(fit1)
summary(malli_lm1)
```

```
#keskiarvojen profiilikuvio
interaction.plot(ahtas ,supu, pala,
                 xlab="Asumisahtaus", ylab="Pinta-ala",
                 trace.label="Sukupuoli", las=1, lwd=2)
```

```
#Tukeyn testi
tukey.test1<-TukeyHSD(malli_lm1)
tukey.test1
plot(tukey.test1)
```

Regressiomalli:

```
#selittäjien väliset korrelaatiot
cor.test(rkyks, alaika, method="pearson")
cor.test(rkyks, asmenot, method="pearson")
cor.test(alaika, asmenot, method="pearson")
```

```
#sirontakuvio
plot(rkyks,pala)
abline(lm(pala~rkyks))
```

```
#sirontakuvio
plot(asmenot,pala)
abline(lm(pala~asmenot))
```

```
#sirontakuvio
plot(alaika,pala)
abline(lm(pala~alaika))
```

```
#korrelaatiokertoimet
cor.test(rkyks, pala,method="pearson")
cor.test(rkyks, pala,method="spearman")
cor.test(asmenot, pala,method="pearson")
cor.test(asmenot, pala,method="spearman")
cor.test(alaika, pala,method="pearson")
cor.test(alaika, pala,method="spearman")
```

```
#yhden selittäjän regressiomalli
lm.pala2 <- lm(pala~rkyks)
summary(lm.pala2)
```

```
#jaannosdiagnostiikka
hist(resid(lm.pala2))
plot(lm.pala2)
```

Toistomittaus

```
#toistomittaus
library(foreign)
ht2.dat<-read.spss("Toistomittausaineisto2020.sav", to.data.frame=TRUE)
attach(ht2.dat)
# Suluissa olevan 1:n tilalle oma opiskelijanumero
set.seed(520829)
# 500 kokoinen otos
oma.otos2<-ht2.dat[sample(nrow(ht2.dat), 500), ]
attach(oma.otos2)

#rajataan erikseen oleelliset muuttujat ja poistetaan tyhjät havainnot
oma.otos2<-oma.otos2[,c(4,15,21)]
oma.otos2<-na.exclude(oma.otos2)

id<-1:488
oma.otos2<-cbind(oma.otos2,id)

#sukupuolineutraalit tunnusluvut
summary(Functional_M1)
summary(Functional_M2)
sd(oma.otos2$Functional_M1)
sd(oma.otos2$Functional_M2)

#tunnusluvut sukupuolittain
# Functional_M1 keskiarvot soluittain
with(oma.otos2,tapply(Functional_M1,list(D2),mean))

# Functional_M1 mediaanit soluittain
with(oma.otos2,tapply(Functional_M1,list(D2),median))

# Functional_M1 keskihajonnat soluittain
with(oma.otos2,tapply(Functional_M1,list(D2),sd))

# Functional_M2 keskiarvot soluittain
with(oma.otos2,tapply(Functional_M2,list(D2),mean))

# Functional_M2 mediaanit soluittain
with(oma.otos2,tapply(Functional_M2,list(D2),median))

# Functional_M2 keskihajonnat soluittain
with(oma.otos2,tapply(Functional_M2,list(D2),sd))

#Laatikko-jana -kuviot
```

```

boxplot(Functional_M1,Functional_M2)
boxplot(Functional_M1~D2)
boxplot(Functional_M2~D2)

#sukupuolineutraalit normaalisuustestit
shapiro.test(Functional_M1)
shapiro.test(Functional_M2)

# Tehdään normaalisuustestit sukupuolen tasoilla
with(oma.otos2,tapply(Functional_M1,list(D2),shapiro.test))
with(oma.otos2,tapply(Functional_M2,list(D2),shapiro.test))

library(tidyr)
dat_long<- oma.otos2 %>%
  gather(key="ohjaus", value="arvo", factor_key = TRUE, -c(id,D2))
fit2<- aov(arvo ~D2 * ohjaus + Error(id/ohjaus), data=dat_long)
summary(fit2)

# Keskiarvojen profiilikuvio
attach(dat_long)
interaction.plot(ohjaus,D2,arvo, data=dat_long)
detach (dat_long)
library(dplyr)

#
Miehet <- select(filter(oma.otos2, D2=="male"),c(D2,Functional_M1,Functional_M2))
Naiset <- select(filter(oma.otos2, D2=="female"),c(D2,Functional_M1,Functional_M2))
MiehetF1<- Miehet$Functional_M1
NaisetF1<- Naiset$Functional_M1
MiehetF2<- Miehet$Functional_M2
NaisetF2<- Naiset$Functional_M2
#t-testit
t.test(MiehetF1,MiehetF2, paired = T)
t.test(NaisetF1,NaisetF2, paired = T)
t.test(Functional_M1,Functional_M2, paired = T)

```

Kategoristen vastemuuttujien mallitus

```

#kategoristen vastemuuttujien mallitus
library(foreign)
ht3.dat<-read.spss("EK2011.sav", to.data.frame=TRUE)
attach(ht3.dat)

```

```

# Suluissa olevan 1:n tilalle oma opiskelijanumero
set.seed(520829)
# 800 kokoinen otos
oma.otos3<-ht3.dat[sample(nrow(ht3.dat), 800), ]
attach(oma.otos3)

table(d2)
table(d32)
table(k23)

mytable <- table(d2,d32,k23)
ftable(mytable)

# loglineaarinen mallitus
library(MASS)
mytable <- xtabs(~d2+d32+k23, data=oma.otos3)

# täydellinen riippumattomuus
loglm(~d2+d32+k23, mytable)

# d2 riippumaton muuttujaparista
loglm(~d2+d32+k23+d32*k23, mytable)

# d32 riippumaton muuttujaparista
loglm(~d2+d32+k23+d2*k23, mytable)

# k23 riippumaton muuttujaparista
loglm(~d2+d32+k23+d2*d32, mytable)

#ehdollinen riippumattomuusmalli: d2 ja k23 riippumattomia
loglm(~d2+d32+k23+d2*d32+d32*k23, mytable)

#ehdollinen riippumattomuusmalli: d2 ja d32 riippumattomia
loglm(~d2+d32+k23+d2*k23+d32*k23, mytable)

#ehdollinen riippumattomuusmalli: d32 ja k23 riippumattomia
loglm(~d2+d32+k23+d2*d32+d32*d2, mytable)

#parittaisten riippuvuuksien malli
loglm(~d2+d32+k23+d2*d32+d32*k23+d2*k23, mytable)

# standardoidut jäännökset
resid(loglm(~d2+d32+k23+d2*k23, mytable))

# mallin jatkotarkastelu
taulu1 <- table(k23,d2)
prop.table(taulu1, 1)
taulu2 <- table(k23,d32)

```

```

prop.table(taulu2, 1)

#Kaksiluokkainen selittävä muuttuja
# logistinen binäärinen regressio
logr_d32 <- glm(d32 ~ d2+ika, data=oma.otos3, family=binomial)
logr_d32

# p-arvot
summary(logr_d32)

# Odds Ratios
exp(cbind(OR=coef(logr_d32), confint(logr_d32)))

# Selityssaste
library(fmsb)
data.nagel<-NagelkerkeR2(logr_d32)
data.nagel

```

Monimuuttujamenetelmät

```

#monimuuttujamenetelmät
library(foreign)
ht4.dat<-read.spss("pankkiotos2020.sav", to.data.frame=TRUE)
attach(ht4.dat)
# Sulussa olevan 1:n tilalle oma opiskelijanumero
set.seed(520829)
# 1600 kokoinen otos
oma.otos4<-ht4.dat[sample(nrow(ht4.dat), 1600), ]
attach(oma.otos4)
oma.otos4<-na.exclude(oma.otos4)

#korrelaatiokertoimet
data.kor2<-cor(oma.otos4, method = "pearson", use = "complete.obs")
View(data.kor2)

#korrelaatiokertoimien p-arvot
library(Hmisc)
res2 <- rcorr(as.matrix(oma.otos4))
View(res2[["P"]])

# korrelaatiokertoimet ja p-arvot rinnakkain
flattenCorrMatrix <- function(cormat, pmat) {
  ut <- upper.tri(cormat)
  data.frame(

```

```

    row = rownames(cormat)[row(cormat)[ut]],
    column = rownames(cormat)[col(cormat)[ut]],
    cor =(cormat)[ut],
    p = pmat[ut]
  )
}
res3<-rcorr(as.matrix(oma.otos4))
View(flattenCorrMatrix(res3$r, res3$P))

#korrelaatioiden voimakkuudet kuviona
library(corrplot)
corrplot(data.kor2, type = "upper", order = "hclust",
          tl.col = "black", tl.srt = 45)

#korrelaatiomatriisin sopivuus pääkomponenttianalyysiin
library (psych)
cortest.bartlett(data.kor2, n =1598,diag=TRUE)
KMO(data.kor2)

#pääkomponenttianalyysi
pca1<-prcomp(oma.otos4,center = T,scale =T)
summary(pca1)

#ominaisarvot
(pca1$sdev)^2
#
screeplot(pca1, type="lines") +
  abline(h=1, lty=2)

# Valitaan viisi pääkomponenttia, promax-rotatio
pca.chosen <- pca1$ rotation [ ,1:5]
pca.promax <- promax (pca.chosen )
pca.promax
# muuttujien selitys päämuuttujilla
p<-ncol(oma.otos4)
n<-nrow(oma.otos4)
e<-eigen(data.kor2)
L<-e$values #placing the eigenvalues in L
Vm<-matrix(0,nrow=p,ncol=p) #creating a p x p matrix with zeroes.
#Vm is an orthogonal matrix since all correlations between variable are 0.
diag(Vm)<-L #putting the eigenvalues in the diagonals
View(Vm) #check-- matrix with eigenvalues on the diagonals
comp.matrix<-e$vectors %*% sqrt(Vm) #sometimes referred to as P matrix
#or eigenvectors x sqrt(Vm): P %*% t(P) is equal to the R matrix.
View(comp.matrix)
#Pääkomponentti 1 selittämä osuus muuttujien vaihtelusta
comp.matrix[,1]^2
#Pääkomponentti 2 selittämä osuus muuttujien vaihtelusta

```

```

comp.matrix[,2]^2
#Pääkomponentti 3 selittämä osuus muuttujien vaihtelusta
comp.matrix[,3]^2
#Pääkomponentti 4 selittämä osuus muuttujien vaihtelusta
comp.matrix[,4]^2
#Pääkomponentti 5 selittämä osuus muuttujien vaihtelusta
comp.matrix[,5]^2
# kommunaliteetit
comp.matrix[,1]^2 +comp.matrix[,2]^2 +comp.matrix[,3]^2 +comp.matrix[,4]^2
+comp.matrix[,5]^2
pcapoints5<-pca1$x[,1:5]
pcapoints5<-as.data.frame(pcapoints5)
names(pcapoints5)<-c("korttiaktiivisuus", "rahastot", "tiliaktiivisuus", "lainat/luotot",
"osakkeet")
#lisätään havaintomatriisiin muuttujiksi nimetyt pääkomponenttipistemäärät
oma.otos45<-cbind(oma.otos4,pcapoints5)
cor(pcapoints5)
# 2 klusteria
set.seed(520829)
km2 = kmeans(pcapoints5, 2, nstart=100)
km2
#3 klusteria
set.seed(520829)
km3 = kmeans(pcapoints5, 3, nstart=100)
km3
#4 klusteria
set.seed(520829)
km4 = kmeans(pcapoints5, 4, nstart=100)
km4
#5 klusteria
set.seed(520829)
km5 = kmeans(pcapoints5, 5, nstart=100)
km5
#klusterien graafinen tarkastelu
library(factoextra)
fviz_cluster(km2, data = oma.otos4,ggtheme = theme_minimal(),
  main = "Clustering Plot")
fviz_cluster(km3, data = oma.otos4,ggtheme = theme_minimal(),
  main = "Clustering Plot")
fviz_cluster(km4, data = oma.otos4,ggtheme = theme_minimal(),
  main = "Clustering Plot")
fviz_cluster(km5, data = oma.otos4,ggtheme = theme_minimal(),
  main = "Clustering Plot")

```

