


Projektityö 1 - Klusterointi


Aineisto 'salary' muodostuu n=50 eri pääaineen palkkajakautaman 10%, 25% ,75% sekä 90% kvantiileista. Muunnettuna ($D=50 \times 50$) etäisyysmatriisiksi, aineistosta voidaan verrata eri alojen osajien palkka-rakenteita suhteutettuna. Pienet etäisyys-arvot kuvaavat siis samankaltaista palkkajakautamaa kahden pääaineen välillä. Lähtökohta on melko heterogeeninen otos alojen tulo-määristä. Voidaan siis sanoa, että alojen palkkatulojen välillä on huomattavia eriyävyyksiä.

Tässä pyrkimyksenäni on ryhmyyttää pääalat klustereihin. Ottaen huomioon projektin asetelma, on tässä suotuisaa käyttää hierarkista klusterointia. Pysin siis löytämään aineistosta homogeenisia ryhmiä, sekä analysoin niiden mahdollisia samankaltaisuuksia ja pääpiirteitä. Eli ryhmytän alat, joiden tulorakenteet ovat samankaltaisia keskenään. Klusterien lopullinen lukumäärä määrätään myöhemmin.




Yllä on etäisyysmatriisista muodostettu lämpökartta. Yleisesti voidaan sanoa että aineistossa ilmenee melko paljon suuria etäisyyksiä, toisin sanoen hajonta on melko suurta. Suurimpia etäisyyksiä voidaan huomata 'Chemical Engineering' sekä 'Economics' havainnoille. Näille molemmille voidaan havaita poikkeuksellisen suuret arvot 90% kvantiilille alkuperäisessä 'salary'-aineistossa, mutta eivät siitä huolimatta ole keskenään kovin samankaltaisia. Näitä voidaan pitää muista merkittävimmin poikkeavina havaintoina suurten etäisyyksien johdosta. Lyhyitä etäisyyksiä voidaan havaita mm. 'Spanish'-'Sociology'-'Religion'-'Psychology' neliö. Näillä aloilla on siis jonkinlaisia samankaltaisuuksia palkkarakenteissa ja todennäköisesti kuuluvat samaan klusteriin.


Tutkin klustereita kolmen linkitys-tyypin kautta: täydellisen linkityksen, yksittäisen linkityksen sekä keskimääräisen linkityksen. Valitsen analysoitavaksi sopivan linkitystavan, josta valitsen mielekkään määrän klustereita. Tulen myös täydentämään havaintoja tarvittaessa myös muiden linkitysten avulla. Aloitan siis visualisoimalla hierarkkinen klusterointi erikseen kolmella eri-linkityksellä 'salary'- aineistosta muunnetusta etäisyysmatriisista. Valitsen näistä klusteroinneista mielekkään visualisoinnin, jota analysoin pääsääntöisesti. Valittuani klusterien määrän, teen tulkintaa klusterien sisäisistä piirteistä sekä klusterien välisistä eroavaisuuksista. Pohdin myös alojen välisiä eroja ja syitä, miksi palkkarakenteet ovat erilaisia. Olennaista on analysoida klusterien välisten etäisyyksien avulla.



Yllä hierarkisesti klusteroitu aineisto täydellisellä linkityksellä. Valitaan pääsääntöisesti tutkittavaksi seitsemän klusteria, sillä nopeasti voi havaita selkeää rakennetta näiden seitsemän klusterin siällä. Oletetusti pääalat ovat nyt homogeenisissa ryhmissä palkkarakenteiden mukaan. Vasemman puoleinen klusteri koostuu kahdesta havaintoyksiköstä, jotka huomattiin erottuvan muista lämpökartasta. Todetaan, että kyseiset 'Economics' sekä 'Chemical Engineering' tosiaan ovat poikkeavia havaintoja. Vasemmalta tulkiten kolmannessa klusterissa kiinnostavaa rakennetta. Nähdään, että insinöörialat sekä saman henkiset (mm. 'physics', 'computer science') muodostavat oman klusterinsa. Pohjalta katsoen insinöörialat 'Aerospace-', 'Computer-', sekä 'Electrical-' kuuluvat lähes samaan haaraan eli näillä kolmella on siis hyvin samankaltaiset palkkajakaumat. Ainoa insinöörihenkinen ala/nimike joka ei kuulu tähän klusteriin on 'Physician Assistant', jonka

voidaan huomata yksittäisen- sekä tasamääräisen linkityksen visualisoinnista kuuluvan eniten poikkeaviin havaintoihin.





Samaan ylä-haaraan insinööri-klusterin kanssa kuuluu melko pieni klusteri, jossa on samassa haarassa 'Math' sekä toinen hyvin matemaattikka-keskeinen ala, 'Financing'. Tässä klusterissa on ehkä hieman yllättävä haara johon kuuluu 'Political Science', 'Marketing' sekä myöhemmin liittyvä 'Philosophy'. Näille aloille on vaikea löytää yhtäläisyyksiä. Ylä-tasolta katsottuna, siirrytään tulkitsemaan visualisaation oikeaa puolta. Kahdessa oikeanpuoleisessa klusterissa on huomattavasti paljon sosiaali-alan työntekijöitä sekä aloja jonka harjoittajista voi olettaa monien työskentelevän opettajina peruskouluissa tai toisella asteella, kuten alat 'English', 'Art History', 'Psychology' sekä 'Education'. Kuvion oikeassa laidassa nähdään viisi opetus-alaa hyvin lähekkäin. Näistä klustereista poikkeavin havainto on 'Drama' joka on myös yleinen ala opettajana. Poikkeavuus suurimmaksi osaksi johtuu korkeasta 90% kvantiiliin tuloista. Voidaan siis olettaa että alalla on todennäköisesti opetusta korkeammat uramahdollisuudet. Kuudennessa klusterissa on luonteeltaan melko hajanaisia aloja, kuten 'Forestry', 'Criminal Justice' sekä 'Graphic Design' lähekkäin. Viides klusteri on hyvin pieni. Siihen kuuluu aiemmin poikkeavaksi tarkasteltu 'Physics Assistant' sekä 'Architecture' ja 'IT', joiden aloilla en löydä samankaltaisuuksia. Neljännessä klusterissa

on myös melko eriluontoisia havaintoyksiköitä. Yllättävää on ettei historian osaajat kuulu samaan klusteriin kuin mm. taidehistorian tai perinteisten kouluaineiden osaajat. Merkittävimpiä havaintoja analyysissä ovat insinöörialojen muodostama oma klusteri eli kuinka saman kaltaiset palkkarakenteet insinöörihenkisillä aloilla on. Muuten palkkarakenteet ovat hyvin hajautettuja alojen luonteiden mukaan. Tämän saattaa selittää pienet tekijät sekä 10% ja 90% kvantiilien yllättävän suuret hajonnat.

```
library(jpeg)
library(tidyverse)
library(tensorBSS)
library(MASS)

D <- as.matrix(dist(salary))
view(D)

#varmistetaan, että etäisyysmatriisi on symmetrinen
D <- (D + t(D))/2

#piirretään heatmap
heatmap(sqrt(D), Rowv = NA, Colv = NA, revC = TRUE, scale = "none")

#Klusterointi: täydellinen linkitys
clust_compD <- hclust(as.dist(D), method = "complete")
plot(clust_compD)

#Klusterointi: yksittäinen linkitys
clust_singleD <- hclust(as.dist(D), method = "single")
plot(clust_singleD)

#Klusterointi: keskimääräinen linkitys
clust_avgD <- hclust(as.dist(D), method = "average")
plot(clust_avgD)
```