

Työn kohteena pidetään R-paketin nlme aineistoa Alfalfa. Aineiston rivit kuvaavat sadon määriä (Yield) päämielenkiinnonkohteena on selvittää lajikkeen (Variety) ja leikkausajankohdan (Date) vaikutusta satoon. Satunnaisvaikutuksella mallinnetaan peltotilkkujen vaikutusta satoon, ja harjoitustyössä kannattaakin vertailla useampia eri vaihtoehtoja mallin satunnaisosaksi

Tutkittu aineisto kuvaa siis eri lajikkeiden sekä niihin suunnattujen käsittelyjen tuomaa satoa maanviljelyssä. Työn tavoite on tutkia näiden kahden muuttujan vaikutusta vasteeseen, Yield. Aineiston rakenne on seuraava:


- Block
 - Kuusi peltoa
- Plot
 - Neljä osapeltoa
- Varieties
 - Kukin Osapelto sisältää yhden jokaista kasvilajiketta
 - Kukin osapelto on jaettu kolmeen osaan Cossack, Ladak, Ranger

Lajikkeet jaettu satunnaisesti kunkin pellon osapelloille ja käsittelyt, eli leikkausajankohdat, satunnaistettiin osapelloille. Näin lajikkeiden viljely on jaettu 72:een alueeseen.

Aineiston rakenne näyttää siis seuraavalta:

Variety	Date	Block	Yield
Cossack:24	None:18	1:12	Min. :0.880
Ladak :24	S1 :18	2:12	1st Qu.:1.310
Ranger :24	S20 :18	3:12	Median :1.585
	O7 :18	4:12	Mean :1.597
		5:12	3rd Qu.:1.820
		6:12	Max. :2.340

visualisoidaan aineistoa ensin ggplotin avulla



Eri pelloilla näyttää olevan vaikutusta ainakin sadon yleiseen tasoon. Peltöjen vaikutus satoon ei kuitenkaan ole tutkimuksen mielenkiinnon kohteena mutta on kuitenkin huomioitavaa. Lajikkeiden käsittelyistä nollakäsittely vaikuttaa varsin hyvältä vaihtoehdolta. Aikaiset kasvien leikkaamiset näyttävät heikentävän lopputulosta. Kuvasta voi nähdä lineaarista trendiä lähes kaikilla pelto-lajike pareilla. Lajikkeista hankala sanoa sadoltaan parasta, tosin Ranger-lajikkeeseen käsittelyt näyttävät tehoavan vähiten. Joillakin lajikkeilla näyttää siis olevan Suurempaa hajontaa kuin toisilla

Luodaan nyt erilaisia malleja erilaisilla satunnaisosilla joista voidaan johtaa tehokkain malli kuvaamaan aineistoa.

Mallissa fit_1 on satunnaisvaikutus jokaiselle pelto-lajike parille, fit_2 sisältää sekä pelto-lajike satunnaismuuttujan, myös kunkin pellon satunnaisvaikutuksen.

Näistä kahdesta mallista valitaan tutkittavaksi varianssianalyysin avulla aineistoa paremmin kuvaava malli.

```
fit_1: Yield ~ 1 + Date + Variety + (1 | Block:Variety)
fit_2: Yield ~ 1 + Date + Variety + (1 | Block) + (1 | Block:Variety)
      npar      AIC      BIC logLik deviance  Chisq Df Pr(>Chisq)
fit_1      8  4.3918 22.605 5.8041  -11.608
fit_2      9 -0.6273 19.863 9.3136  -18.627  7.0191  1    0.008065 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Merkittävästi paremmaksi malliksi osoittautuu mallinvalintakriteerein fit_2. myös uskottavuusosamäärän ollessa suuri, tuetaan merkittävästi mallin 2 paremmuutta.

Suoritetaan ensin alustavaa mallin parametriestimaattien tulkintaa:

```
> summary(fit_2)
Linear mixed model fit by REML ['lmerMod']
Formula: Yield ~ 1 + Date + Variety + (1 | Block) + (1 | Block:Variety)
Data: data
```

REML criterion at convergence: 2.3

Scaled residuals:

Min	1Q	Median	3Q	Max
-1.78582	-0.63029	-0.00621	0.54446	1.83225

Random effects:

Groups	Name	Variance	Std.Dev.
Block:Variety	(Intercept)	0.02686	0.1639
Block	(Intercept)	0.05781	0.2404
Residual		0.02881	0.1697

Number of obs: 72, groups: Block:Variety, 18; Block, 6

Fixed effects:


	Estimate	Std. Error	t value
(Intercept)	1.75597	0.12850	13.665
DateS1	-0.44056	0.05657	-7.787
DateS20	-0.20667	0.05657	-3.653
Date07	-0.09000	0.05657	-1.591
VarietyLadak	0.09458	0.10655	0.888
VarietyRanger	-0.01917	0.10655	-0.180

Correlation of Fixed Effects:

	(Intr)	DateS1	DateS20	Date07	VrtyLd
DateS1	-0.220				
DateS20	-0.220	0.500			
Date07	-0.220	0.500	0.500		
VarietyLadk	-0.415	0.000	0.000	0.000	
VarietyRngr	-0.415	0.000	0.000	0.000	0.500


Huomataan, että block-variety ryhmien välinen vaihtelu on lähes sama kuin ryhmien sisäinen vaihtelu. Peltojen välinen vaihtelu on taas noin kolmasosan ryhmien sisäistä vaihtelua suurempaa.

Nyt halutaan arvioida mallin soveltuvuutta sekä varmistaa, että mallin oletukset täyttyvät diagnostiikan avulla. Tarkastetaan ensin mallin kovarianssirakenne jäännösten ja havaintoindeksin kuvaajasta.



Vasemmalla kukin lajike omassa sektiossaan ja oikealla kukin pelto-lajike erikseen. Tasojen virhevariansseilla näyttää olevan hieman heteroskedastisuutta. Viimeisillä indekseillä vasemmassa kuvassa voidaan huomata merkittävän pientä varianssia. Tämä on siis

Ranger-lajike. On siis sopivaa epäillä että olisi yhä sopivampi malli kuvaamaan aineistoa. Vilkaistaan vielä skaalattujen jäännösten sekä sovitteiden kuvaajaa



jäännösten sekä soviteen hajontakuviosta voidaan kenties havaita lineaarista riippuvuutta. Tämä voi tarkoittaa että malliin voisi sopia lisää selittäviä muuttujia tai nähtyjen tulosten perusteella voidaan epäillä myös Date- muuttujan vaikuttavan lineaarisesti.

Verrataan fit_2- mallia muutamaan malliin jossa voidaan ottaa varianssistruktuuri huomioon.

Luodaan nlme-paketilla uusia malleja. Voidaan epäillä että malliin tarvitaan osa, joka huomioisi lajikkeiden-välisen heteroskedastisuuden. Aikaisemman summary(fit_2) mukaan voidaan nähdä sopivaksi kuvata riippuvuusrakenteet compound symmetry-muodossa. Näin saadaan kaksi mallia.

```
fit_nlme_1 <- lme(Yield ~ 1 + Date + Variety, data = data, method = "ML",
  random = list(Block = pdCompSymm(~ 1 + Variety)))
fit_nlme_2 <- lme(Yield ~ 1 + Date + Variety, data = data, method = "ML",
  random = list(Block = pdCompSymm(~ 1 + Variety)),
  weights = varIdent(form = ~ 1 | Variety))
```

Jossa kummassakin on huomioitu compound symmetry varianssirakenne sekä toisessa mallissa varIdent- osa joka sallii jokaiselle lajikkeelle oman varianssinsa. Valitaan myös että jokaiselle lajikkeelle saadaan oma intercept.

	Model	df	AIC	BIC	logLik	Test	L.Ratio	p-value
fit_nlme_2	1	11	-2.0086470	23.03468	12.004324			
fit_nlme_1	2	9	-0.6272706	19.86272	9.313635	1 vs 2	5.381376	0.0678

Mallien vertailun p-arvo anova-funktiolla kertoo että yksinkertaisempi malli 1 ole huonompi kuin malli 2. verrataan nyt mallia fit_nlme_1 malliin fit_2.

```

          df      AIC
fit_2      9 20.347434
fit_nlme_1  9 -1.147327
> BIC(fit_2, fit_nlme_1)
          df      BIC
fit_2      9 40.83743
fit_nlme_1  9 19.34267

```

Varianssirakenteen huomioiva fit_nlme_2 on kriteerien mukaan paljon suotuisampi malli. Jatketään siis sillä.

```

Random effects:
Formula: ~1 + Variety | Block
Structure: Compound Symmetry
StdDev      Corr
(Intercept) 0.2220068
VarietyLadak 0.2220068 -0.328
VarietyRanger 0.2220068 -0.328 -0.328
Residual     0.1641099

Fixed effects: Yield ~ 1 + Date + Variety
          Value Std.Error DF   t-value p-value
(Intercept)  1.7559722 0.10681596 61 16.439231 0.0000
DateS1       -0.4405556 0.05713575 61 -7.710681 0.0000
DateS20      -0.2066667 0.05713575 61 -3.617117 0.0006
Date07       -0.0900000 0.05713575 61 -1.575196 0.1204
VarietyLadak  0.0945833 0.10681596 61  0.885479 0.3794
VarietyRanger -0.0191667 0.10681596 61 -0.179436 0.8582

Correlation:
(Intr) DateS1 DateS20 Date07 VrtyLd
DateS1    -0.267
DateS20    -0.267  0.500
Date07     -0.267  0.500  0.500
VarietyLadak -0.365  0.000  0.000  0.000
VarietyRanger -0.365  0.000  0.000  0.000 -0.150

```

Mallin tulosteesta nähdään että satunnaismuuttujilla on enemmän vaihtelua kuin satunnaistajien virhevaihtelu. Tämä näyttää paremmalta kuin aikaisemman fit_2 tulosteessa. Kiinteille vaikutuksille yhä pätee samat arviot kuin fit_2- tulosten analysoinnissa tehtiin.

```

Fixed effects:
          lower      est.      upper
(Intercept)  1.5514737 1.75597222 1.96047071
DateS1       -0.5499416 -0.44055556 -0.33116951
DateS20      -0.3160527 -0.20666667 -0.09728063
Date07       -0.1993860 -0.09000000  0.01938604
VarietyLadak -0.1099152  0.09458333  0.29908182
VarietyRanger -0.2236652 -0.01916667  0.18533182

Random Effects:
Level: Block
          lower      est.      upper
std. dev  0.1446813 0.2220068 0.3406594
corr.     -0.4721641 -0.3280693 0.2048228

```

Luottamusväleistä nähdään että satunnaistekijät ovat olennaiset mallissa sillä nolla ei sisälly satunnaismuuttujan keskihajonnan luottamusväliin. Korrelaatio tosin saattaa olla nolla.

```

> pairs(emmeans(fit_nlme_1, specs = "Date"), infer = c(TRUE, FALSE))
contrast      estimate      SE df lower.CL upper.CL
None - S1      0.441 0.0571 61   0.2896   0.5915
None - S20     0.207 0.0571 61   0.0558   0.3576
None - 07      0.090 0.0571 61  -0.0609   0.2409
S1 - S20     -0.234 0.0571 61  -0.3848  -0.0830
S1 - 07      -0.351 0.0571 61  -0.5015  -0.1996
S20 - 07     -0.117 0.0571 61  -0.2676   0.0342

```

kontrastien luottamusväleistä nähdään että Kiinteiden tekijöiden parittaisista tarkasteluista nähdään, kuten alun visualisoinnista arveltiin, että käsittelyt eivät ole selvästi nollakäsittelyä parempia. Ajankohtaesimaatit BetaHat ovat enemmän tai vähemmän negatiivisia. Betahat tulkinta: uusi satunnaisesti valittu osapello, jolle suoritetaan kolmas leikkaus kokeessa 1.syyskuuta vastaavana ajankohtana, tuottaisi noin 0.44 yksikön verran pienempää satoa.


Parittaisten vertailujen regressiokertoimista voitaisiin sanoa, että kolmannen leikkuun lykkääminen myöhemmäksi tutkimuksen aika-skaalassa on kannattavaa. Sadon kasvu S1 ja S20 välillä on kaksinkertaisesti suurempaa kuin sadon kasvu ajalla S20 ja O7. Siitä huolimatta että kasvu hidastuu merkittävästi, kontrastien luottamusvälit kertovat, että visuaalisista eroista ja regressiokertoimien negatiivisuudesta huolimatta S20 ja O7 käsittelyillä ei voida sanoa olevan eroa. Yhden aikapisteen hyppy on vasteeseen merkittävä vain S1 ja S20 välillä luottamusvälin mukaan. Kaikki usean aikapisteen hyppyt ovat merkittäviä eli lisäävät merkittävästi sadon määrää.

```
> pairs(emmeans(fit_nlme_1, specs = "Variety"), infer = c(TRUE, FALSE))
```


contrast	estimate	SE	df	lower.CL	upper.CL
Cossack - Ladak	-0.0946	0.107	61	-0.351	0.162
Cossack - Ranger	0.0192	0.107	61	-0.237	0.276
Ladak - Ranger	0.1138	0.162	61	-0.275	0.503

Lajikkeista mikään ei luottamusvälinsä mukaan merkitsevästi eroa toisesta. Huomioitavaa, että Ladak-Ranger erotuksella on muita melko huomattavasti suurempi keskihajonta.

Aloitetaan diagnostiikka piirtämällä jäännösten sekä sovitteiden välinen hajontakuvio




Ei havaittavissa mitään silmäänpistävää. Jäännösten hajonta näyttää vakiolta kullakin Date-tasolla eikä ole havaittavissa mitään systemaattista muotoa.




Eri Lajikkeille sovitteiden sekä jäännösten kuva näyttää myös hyvältä hajonnan suhteen. Jokaisella lajikkeella näyttää olevan tasainen hajonta jokaisella sovitteen arvolla.


Normal Q-Q Plot



Jäännösten jakauma on hieman vasemmalle vino. pieniä katkoksia voidaan havaita mutta pieni huoli tässä sillä vinous on lievää.



Jäännösten hajonta kullakin sovitteen lajikkeella. Kuvaaja näyttää melko hyvältä. Malliin ei tarvittu mukaan tekijää, jolla jokaisella lajikkeella olisi oma varianssirakenne ja tämä todistaa sen puolesta että väärää valintaa ei tehty.



Kuvasta voidaan nähdä että Ladak muuttujan vaikutus satunnaismuuttujaan on ehkä eniten muista poikkeava. Kaikki tämä voi kuitenkin selittää satunnaisvaihtelulla huomioiden pieni tasojen määrä.

